Auditoria dels quatre pecats d'un conjunt de reserves

Aquesta pràctica posa en pràctica els continguts de la UT2: detectar de manera sistemàtica els quatre pecats de les dades sobre un conjunt de reserves de trasllats semblant al de la UT1, però més brut. Recordeu-los: els **valors incorrectes** (fora de domini, inconsistents entre camps o duplicats), l'**absència de valors** (NaN, pseudo-buits i sentinelles, amb patrons MCAR, MAR o MNAR), la **mala codificació** (números com a text, dates barrejades, variants de categoria, mojibake) i els **valors atípics** (regles 3σ i IQR, i la diferència entre un atípic i un error). Cada secció tracta un pecat, i la darrera en consolida les troballes en un informe d'anomalies. Al llarg de tota la pràctica només es **detecta, quantifica i marca**: no heu de corregir, omplir ni eliminar cap dada, perquè aquestes decisions són feina de la unitat de neteja. Es dona per fet que ja disposeu d'un entorn Python gestionat amb `uv`; les úniques llibreries que calen són `pandas` i `numpy`. Els exercicis de cada secció van de menor a major dificultat, i els més llargs inclouen un esquelet de codi: només heu d'omplir els forats marcats amb `....`

1 Generació i radiografia del conjunt

Exercici 1

Descarregueu, al vostre directori de treball, els scripts `generar_dataset.py` i `generar_domini.py` (els trobareu al mateix lloc que aquesta pràctica) i executeu el primer amb `uv`:

```
$ uv run generar_dataset.py
```

Comproveu que s'ha creat `reserves_brut.csv`. L'script fa servir sempre la mateixa llavor aleatòria: si l'executeu més d'una vegada, obtindreu exactament el mateix fitxer.

Exercici 2

Partint de les observacions que vau anotar a l'exercici 2 de la UT1, feu una radiografia ràpida de `reserves_brut.csv` (dimensions, tipus inferits, cardinalitats i estadístics de les columnes numèriques) i comproveu quines es repeteixen en aquest conjunt. Per a cadascun dels quatre pecats, anoteu com a mínim una sospita que ja us cridi l'atenció. Les comprovareu a les seccions següents.

2 Pecat 1: valors incorrectes

Per detectar valors fora de domini cal saber quin és el domini de cada variable. La taula següent recull les regles de negoci de l'empresa de trasllats:

Variable	Domini de negoci
`id`	`R` seguida de 4 dígits; única per reserva
`client_id`	`C` seguida de 3 dígits
`zona`	`PALMA`, `CALVIA`, `LLEVANT`, `NORD`
`km`	entre 1 i 400
`import`	entre 0 i 1500 €; una reserva cancel · lada no es cobra (import 0)
`estat`	`confirmada`, `cancel·lada`, `pendent`
`canal`	`WEB`, `TELEFON`, `APP`
`creada_el`	data en format `aaaa-mm-dd`, no posterior a la data d'extracció (2026-10-01)
`recollida_el`	data en format `aaaa-mm-dd`, no anterior a `creada_el`
`passatgers`	entre 1 i 8
`codi_postal`	`07` seguit de 3 dígits
`email`	text amb una única `@` i sense espais
`pagat`	`si`, `no`

Exercici 3

Executeu `generar_domini.py` i obriu el `domini_variables.json` que genera. Llegiu el codi de l'script i expliqueu, amb les vostres paraules:

- què fa la funció `infereix_domini` i com decideix si una columna rep un `rang`, una llista de `valors` o res més que un exemple;
- per a què serveix la constant `MAX_CATEGORIES`;
- què fa la funció `aplica_correccions` amb el diccionari `CORRECCIONS_HUMANES`.

Exercici 4

Compareu el domini inferit amb la taula de regles de negoci. Trobeu com a mínim quatre columnes on el domini inferit és incorrecte i, per a cadascuna, digueu quin pecat s'hi ha colat. Expliqueu per què un validador construït sobre aquest domini inferit no trobaria pràcticament cap error.

Exercici 5

Completeu `CORRECCIONS_HUMANES` a `generar_domini.py` perquè cada columna tingui el domini de la taula de negoci, i torneu a generar `domini_variables.json`. Feu servir `"valors"` per a les llistes tancades, `"rang"` per als intervals numèrics i `"patro"` (una expressió regular) per als formats de text. Les regles que relacionen dues columnes (per exemple, una cancel · lada no es cobra) no hi caben: les programareu a l'exercici següent.

Exercici 6

Programeu un validador declaratiu que llegeixi el vostre `domini_variables.json`, en derivi les regles i hi afegeixi tres regles de consistència entre camps: cancel · lades amb import cobrat, recollides anteriors a la creació i reserves creades després de la data d'extracció. Les primeres línies de l'esquelet us donen les conversions de tipus que necessiteu (són feina del pecat 3):

```
import json
import pandas as pd

df = pd.read_csv("reserves_brut.csv")
df["import"] = pd.to_numeric(df["import"].str.replace(",", "."),
                             errors="coerce")
iso = pd.to_datetime(df["creada_el"], format="%Y-%m-%d", errors="coerce")
creada = iso.fillna(pd.to_datetime(df["creada_el"], format="%d/%m/%Y",
                                   errors="coerce"))
recollida = pd.to_datetime(df["recollida_el"], format="%Y-%m-%d")

with open("domini_variables.json", encoding="utf-8") as f:
    domini = json.load(f)

REGLES = {}  # nom -> màscara de files sospitoses
for col, regla in domini.items():
    s = df[col]
    # Els absents no són valors incorrectes (són el pecat 2): excloeu-los
    if "valors" in regla:
        REGLES[f"{col}_fora_valors"] = ...  # no és a la llista
    if "rang" in regla:
        REGLES[f"{col}_fora_rang"] = ...    # no és dins [mínim, màxim]
    if "patro" in regla:
        REGLES[f"{col}_fora_patro"] = ...   # no compleix el patró sencer

REGLES["cancelada_amb_import"] = ...
REGLES["recollida_abans_creada"] = ...
REGLES["creada_futura"] = ...
```

```python
for nom, mascara in REGLES.items():
    print(f"{nom:26s} {...:5d} {...:6.2f} %")  # files i percentatge
```

Interpreteu el resultat: hi ha regles que salten per un altre pecat diferent del d'un valor incorrecte? Quines, i per quin?

Exercici 7

Compteu els duplicats exactes (files idèntiques) i els duplicats lògics (mateix `client_id`, `zona`, `km` i `creada_el`, però un `id` diferent) del conjunt. Assegureu-vos que els duplicats lògics que doneu no inclouen els exactes. Expliqueu què canvia si feu servir `keep=False` en lloc del valor per defecte de `duplicated`, i quin origen probable té cada tipus de duplicat.

3 Pecat 2: absència de valors

Exercici 8

Compteu els NaN de cada columna. Tingueu en compte que, en llegir el CSV, pandas ja converteix en NaN alguns textos habituals com `"N/A"` o `"NULL"`. Feu un inventari dels valors de `email` que no tenen forma d'adreça electrònica i identifiqueu quins són **pseudo-buits**. Identifiqueu també, a les columnes numèriques, quins valors fan de **sentinella**.

Exercici 9

Completeu la funció `absents_reals`, que ha de marcar com a absent qualsevol dels tres graus d'absència:

```python
PSEUDO = {...}  # els pseudo-buits que heu trobat (després de treure espais)

def absents_reals(s, sentinelles=()):
    m = ...           # NaN honestos
    m = m | ...       # pseudo-buits: passeu a text i traieu els espais
    m = m | ...       # sentinelles numèriques
    return m
```

Feu-la servir per construir una taula amb, per a cada columna, el % de NaN, de pseudo-buits, de sentinelles i el % total d'absents reals. Després, calculeu la mitjana de `km` tal com és i excloent-ne les sentinelles, i expliqueu la diferència.

Exercici 10

Calculeu el % d'`email` absent (real) per `canal` i el % de `km` absent per `zona`. Classifiqueu cada absència com a MCAR o MAR i justifiqueu-ho. A continuació, compteu les reserves amb `passatgers = 0` per canal: el 0 és una sentinella o un error de teclat? Quina evidència us ho fa pensar?

Exercici 11

Poseu un exemple plausible, en aquest negoci de trasllats, d'una variable on l'absència podria ser MNAR. Expliqueu per què aquest patró no es pot demostrar només amb les dades que teniu i quin risc tindria omplir-ne els forats amb la mitjana.

4 Pecat 3: mala codificació

Exercici 12

Indiqueu quines columnes haurien de ser numèriques segons la taula de negoci i quin tipus els ha assignat pandas. Per a `import`, calculeu el % de valors que es converteixen a número directament i el % que s'hi converteixen si abans canvieu la coma decimal per un punt.

Exercici 13

Calculeu, amb expressions regulars (`str.match`), el % de valors de `creada_el` en format `aaaa-mm-dd` i en format `dd/mm/aaaa`. Proveu de convertir la columna amb `pd.to_datetime(..., format="mixed", dayfirst=True)` i comproveu què passa amb una data ISO com `2026-03-05`. Per què l'ajuda de l'exercici del validador converteix cada format per separat?

Exercici 14

Completeu la funció de forma canònica i apliqueu-la a `zona` i a `estat`:

```
def canonica(s):
    return (s.str.strip()            # treure espais
            ...                      # passar a majúscules
            .str.normalize("NFKD")   # separar les lletres dels accents
            ...)                     # quedar-se només amb l'ASCII

for col in ["zona", "estat"]:
    c = canonica(df[col])
    print(col, ..., "->", ...)       # cardinalitat abans i després
    variants = df.groupby(c)[col].unique()
    print(variants[...])             # formes amb més d'una variant
```

Per a `zona`, la cardinalitat hauria de baixar fins a les quatre zones reals. Per a `estat`, no ho fa: expliqueu per què, què significa el valor `cancelÂ·lada` i com s'hauria pogut evitar en llegir el fitxer.

Exercici 15

Compteu els codis postals que no compleixen el patró de la taula de negoci i classifiqueu-los segons el tipus d'error. Feu també l'inventari dels valors de `pagat` i proposeu (sense aplicar-lo) un mapa que els tradueixi tots a `si` o `no`.

5 Pecat 4: valors atípics

Exercici 16

Calculeu a mà, sense ordinador, la mitjana, la mediana, la desviació típica, els quartils Q_1 i Q_3, el rang interquartílic i els llindars superiors de les regles 3σ i IQR d'aquests nou trasllats:

$$3 \quad 5 \quad 6 \quad 6 \quad 8 \quad 9 \quad 11 \quad 13 \quad 35$$

El 35 és atípic segons cada regla? Comproveu els resultats amb pandas.

Exercici 17

Completeu els dos detectors d'atípics:

```
def atipics_3sigma(s):
    return ...                  # |x - mitjana| > 3 desviacions típiques
```

```python
def atipics_iqr(s, k=1.5):
    q1, q3 = ...
    iqr = ...
    return ...                  # fora de [Q1 - k·IQR, Q3 + k·IQR]
```

Apliqueu-los a `km` dues vegades: (a) amb tots els valors i (b) excloent-ne les sentinelles i els valors fora de domini. Compareu el nombre d'atípics i el llindar superior de cada regla en els dos casos, i quantifiqueu l'emmascarament que provoquen els valors incorrectes.

Exercici 18

Apliqueu la regla IQR a `km` (sense sentinelles ni valors fora de domini) per separat a cada zona, fent servir la forma canònica de `zona`. Compareu el nombre d'atípics de cada zona amb el que surt aplicant la regla al conjunt sencer, i expliqueu per què la població de referència és una decisió de domini.

Exercici 19

Mostreu les 10 reserves amb l'import més alt, amb els seus `km` i l'import per quilòmetre. Proposeu un criteri per separar els atípics legítims dels errors i classifiqueu cada reserva. Quin error concret sospiteu en els imports erronis?

6 Cas integrador: l'informe d'anomalies

Exercici 20

Consolideu en un sol fitxer `reserves_amb_marques.csv` el conjunt original amb una columna booleana `err_*` per cada regla o detector dels exercicis anteriors, sense modificar cap valor original. Trobeu un exemple de troballa **corregible**, un de **imputable**, un de **a eliminar** i un de **a consultar amb el negoci**.